

PEF 1: Comparación de Modelos para la Predicción de la Volatilidad

Tarea 1.

Miembros del equipo.

1. Alberto De la Peña García
2. Edgar Alejandro Gonzalez Lira
3. Ana Paula Martinez Santos
4. José Pablo Tamez Ayala

Tema.

Comparación de Modelos para la Predicción de la Volatilidad: Un Estudio Empírico Aplicado al Mercado Financiero.

Asesor.

Dr. Martín Lozano Banda.

Objetivo General 1.

Replicar y extender modelos de predicción de volatilidad propuestos en la literatura a través de la implementación de nuevas metodologías y variables explicativas con el fin de comparar e identificar el enfoque más robusto y preciso.

Objetivo Específico 1.1.

Implementar y contrastar metodologías de Machine Learning adicionales.

Objetivo Específico 1.2.

Ampliar el set de variables explicativas y contrastar su poder predictivo frente a los modelos anteriores.

Objetivo Específico 1.3.

Escalar a una base de datos más amplia y reciente para evaluar el desempeño de los modelos bajo diferentes escenarios de mercado.

Objetivo General 2.

Aplicar el mejor modelo de predicción de volatilidad en contextos financieros prácticos para evaluar su valor agregado frente a medidas tradicionales de volatilidad.

Objetivo Específico 2.1.

Identificar y seleccionar diferentes contextos financieros en los que la predicción de volatilidad pueda aportar valor.

Objetivo Específico 2.2.

Diseñar una metodología de implementación que permita contrastar el uso de la volatilidad predicha por los modelos frente a medidas tradicionales.

Tarea 2.

A machine learning approach to volatility forecasting. Christensen et al. (2023)

Este artículo evalúa de forma sistemática qué tan competitivos son diversos algoritmos de *machine learning* (ML) para pronosticar la varianza realizada (RV) frente a la familia de modelos HAR/HAR-X. Aporta una comparación entre métodos de regularización (ridge, lasso, elastic net), árboles (bagging, random forest, gradient boosting) y redes neuronales. También

establece evidencia de que el ML extrae información incremental a partir de covariables adicionales, así como un marco de interpretabilidad basado en *Accumulated Local Effects* (ALE) para entender importancia y relaciones no lineales entre predictores.

Datos y variables.

Utilizan 29 acciones del índice Dow Jones Industrial Average (DJIA), con horizonte de un día adelante, en el periodo 2001-2017. La RV se construye con datos de alta frecuencia. Además de los rezagos diarios, semanales y mensuales de la RV (RVD, RVW, RVM), incorporan la volatilidad implícita (IV), un indicador de anuncio de resultados (EA), un índice de incertidumbre de política económica (EPU), VIX, la tasa T-bill a 1 mes (US1M), *momentum* a 1 semana (M1W), retorno del Hang Seng (HSI), volumen en dólares (DVOL), y el índice ADS de condiciones de negocio. Para organizar la información definen tres conjuntos de datos: M1 (sólo rezagos de RV), M2 (subconjunto “óptimo” vía BIC) y M3 (conjunto amplio de 12+ variables).

Metodología.

Comparan HAR/HAR-X contra: ridge, lasso, elastic net; bagging, random forest, gradient boosting; y varias arquitecturas de redes neuronales “*off-the-shelf*” con ajuste mínimo de hiperparámetros. Evalúan *out-of-sample* con MSE relativo al HAR y emplean *Model Confidence Set* (MCS) al 90% para comparar robustamente. También estudian versiones en log-volatilidad (L-HAR, etc.).

Resultados principales.

- Desempeño predictivo: Los métodos de ML superan consistentemente al HAR; entre ellos, random forest y redes neuronales suelen liderar.
- Información incremental: Frente a HAR-X, el ML extrae más señal de covariables adicionales y maneja mejor correlaciones altas, baja señal/ruido y no linealidades.
- Estados del mercado: ML mantiene ventajas tanto en episodios tranquilos como turbulentos; HAR-X tiende a deteriorarse en alta volatilidad. Con log-volatilidad, L-HAR-X mejora, pero L_NN vuelve a dominar en regímenes medio-altos.

Limitaciones y alcances.

El estudio se centra en acciones del DJIA y en horizontes de un día y persisten preguntas sobre la transferibilidad a otros activos/mercados y el *tuning* de hiperparámetros más agresivo.

Existen diferentes oportunidades de extensión para nuestro proyecto, entre ellas:

- Extender con nuevos métodos de *boosting* moderno (XGBoost/LightGBM), redes recurrentes/transformers para series, y regulación con búsqueda sistemática de hiperparámetros.
- Ampliar variables explicativas de análisis de sentimiento.
- Evaluar más horizontes de tiempo.

The impact of sentiment and attention measures on stock market volatility. Audrino et al. (2020)

Este artículo estudia si medidas de sentimiento (tono en redes/noticias) y atención (volumen de mensajes/búsquedas) aportan poder predictivo adicional para la volatilidad realiazda.

Datos y variables.

- Volatilidad realizada (índice Dow Jones y 18 acciones de EE.UU.) a partir de datos intradía de Oxford-Man Institute.
- Redes sociales: Twitter (muestra histórica 1% de todos los tuits, 2012-2016) y Stock-Twits, de donde se extraen sentimiento (promedios y dispersión diaria) y volumen de mensajes como proxy de atención. El sentimiento se suaviza con filtro de Kalman para reducir ruido.
- Noticias: RavenPack News Analytics (Event Sentiment Score, Composite Sentiment Score, News Impact Score), ponderados por relevancia del artículo para la empresa.
- Atención web: Google Trends (búsquedas) y Wikipedia page views, tanto específicos de empresa como de mercado (“stock market”, “financial markets”, etc.)
- Covariables económicas y financieras: factores Fama-French, ratios precio-fundamental, retornos de índices, VIX, tasas e indicadores de liquidez, entre otros.

Metodología.

- Modelo base: HAR de Corsi para volatilidad realizada (captura persistencia mediante promedios diarios/semanales/mensuales).
- Extensión: Sentiment-HAR, que agrega sentimientos y medidas de atención junto con las variables económicas. Dado el alto número de predictores, emplean adaptive lasso para selección y estimación, con pruebas de significancia conjunta y post-selección conservadoras.

Resultados principales.

Evidencia in-sample:

- Las variables de sentimiento/atención son conjuntamente significativas (F-tests) sobre la volatilidad futura en casi todos los activos (17/18 acciones y el índice).
- La atención domina al sentimiento como forma funcional: el volumen (mensajes/búsquedas) es el predictor más relevante; el VIX aparece sistemáticamente entre las variables seleccionadas.

Desempeño out-of-sample:

- Horizonte 1 día:

Bibliografía

- Audrino, F., Sigrist, F., & Ballinari, D. (2020). The impact of sentiment and attention measures on stock market volatility. *International Journal of Forecasting*, 36(2), 334–357.
- Christensen, K., Siggaard, M., & Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.