

# **PEF 1: Comparación de Modelos para la Predicción de la Volatilidad**

## **Tarea 1.**

### **Miembros del equipo.**

1. Alberto De la Peña García
2. Edgar Alejandro Gonzalez Lira
3. Ana Paula Martinez Santos
4. José Pablo Tamez Ayala

### **Tema.**

Comparación de Modelos para la Predicción de la Volatilidad: Un Estudio Empírico Aplicado al Mercado Financiero.

### **Asesor.**

Dr. Martín Lozano Banda.

### **Objetivo General 1.**

Replicar y extender modelos de predicción de volatilidad propuestos en la literatura a través de la implementación de nuevas metodologías y variables explicativas con el fin de comparar e identificar el enfoque más robusto y preciso.

### **Objetivo Específico 1.1.**

Implementar y contrastar metodologías de Machine Learning adicionales.

### **Objetivo Específico 1.2.**

Ampliar el set de variables explicativas y contrastar su poder predictivo frente a los modelos anteriores.

### **Objetivo Específico 1.3.**

Escalar a una base de datos más amplia y reciente para evaluar el desempeño de los modelos bajo diferentes escenarios de mercado.

## **Objetivo General 2.**

Aplicar el mejor modelo de predicción de volatilidad en contextos financieros prácticos para evaluar su valor agregado frente a medidas tradicionales de volatilidad.

### **Objetivo Específico 2.1.**

Identificar y seleccionar diferentes contextos financieros en los que la predicción de volatilidad pueda aportar valor.

### **Objetivo Específico 2.2.**

Diseñar una metodología de implementación que permita contrastar el uso de la volatilidad predicha por los modelos frente a medidas tradicionales.

## **Tarea 2.**

### **A machine learning approach to volatility forecasting. Christensen et al. (2023)**

Este artículo evalúa de forma sistemática qué tan competitivos son diversos algoritmos de *machine learning* (ML) para pronosticar la varianza realizada (RV) frente a la familia de modelos HAR/HAR-X. Aporta una comparación entre métodos de regularización (ridge, lasso, elastic net), árboles (bagging, random forest, gradient boosting) y redes neuronales. También

establece evidencia de que el ML extrae información incremental a partir de covariables adicionales, así como un marco de interpretabilidad basado en *Accumulated Local Effects* (ALE) para entender importancia y relaciones no lineales entre predictores.

### Datos y variables.

Utilizan 29 acciones del índice Dow Jones Industrial Average (DJIA), con horizonte de un día adelante, en el periodo 2001-2017. La RV se construye con datos de alta frecuencia. Además de los rezagos diarios, semanales y mensuales de la RV (RVD, RVW, RVM), incorporan la volatilidad implícita (IV), un indicador de anuncio de resultados (EA), un índice de incertidumbre de política económica (EPU), VIX, la tasa T-bill a 1 mes (US1M), *momentum* a 1 semana (M1W), retorno del Hang Seng (HSI), volumen en dólares (DVOL), y el índice ADS de condiciones de negocio. Para organizar la información definen tres conjuntos de datos: M1 (sólo rezagos de RV), M2 (subconjunto “óptimo” vía BIC) y M3 (conjunto amplio de 12+ variables).

### Metodología.

Comparan HAR/HAR-X contra: ridge, lasso, elastic net; bagging, random forest, gradient boosting; y varias arquitecturas de redes neuronales “*off-the-shelf*” con ajuste mínimo de hiperparámetros. Evalúan *out-of-sample* con MSE relativo al HAR y emplean *Model Confidence Set* (MCS) al 90% para comparar robustamente. También estudian versiones en log-volatilidad (L-HAR, etc.).

### Resultados principales.

- Desempeño predictivo: Los métodos de ML superan consistentemente al HAR; entre ellos, random forest y redes neuronales suelen liderar.
- Información incremental: Frente a HAR-X, el ML extrae más señal de covariables adicionales y maneja mejor correlaciones altas, baja señal/ruido y no linealidades.
- Estados del mercado: ML mantiene ventajas tanto en episodios tranquilos como turbulentos; HAR-X tiende a deteriorarse en alta volatilidad. Con log-volatilidad, L-HAR-X mejora, pero L\_NN vuelve a dominar en regímenes medio-altos.

### Limitaciones y alcances.

El estudio se centra en acciones del DJIA y en horizontes de un día y persisten preguntas sobre la transferibilidad a otros activos/mercados y el *tuning* de hiperparámetros más agresivo.

Existen diferentes oportunidades de extensión para nuestro proyecto, entre ellas:

- Extender con nuevos métodos de *boosting* moderno (XGBoost/LightGBM), redes recurrentes/transformers para series, y regulación con búsqueda sistemática de hiperparámetros.
- Ampliar variables explicativas de análisis de sentimiento.
- Evaluar más horizontes de tiempo.

## **The impact of sentiment and attention measures on stock market volatility. Audrino et al. (2020)**

Este artículo estudia si medidas de sentimiento (tono en redes/noticias) y atención (volumen de mensajes/búsquedas) aportan poder predictivo adicional para la volatilidad realiazda.

### **Datos y variables.**

- Volatilidad realizada (índice Dow Jones y 18 acciones de EE.UU.) a partir de datos intradía de Oxford-Man Institute.
- Redes sociales: Twitter (muestra histórica 1% de todos los tuits, 2012-2016) y Stock-Twits, de donde se extraen sentimiento (promedios y dispersión diaria) y volumen de mensajes como proxy de atención. El sentimiento se suaviza con filtro de Kalman para reducir ruido.
- Noticias: RavenPack News Analytics (Event Sentiment Score, Composite Sentiment Score, News Impact Score), ponderados por relevancia del artículo para la empresa.
- Atención web: Google Trends (búsquedas) y Wikipedia page views, tanto específicos de empresa como de mercado (“stock market”, “financial markets”, etc.)
- Covariables económicas y financieras: factores Fama-French, ratios precio-fundamental, retornos de índices, VIX, tasas e indicadores de liquidez, entre otros.

### **Metodología.**

- Modelo base: HAR de Corsi para volatilidad realizada (captura persistencia mediante promedios diarios/semanales/mensuales).
- Extensión: Sentiment-HAR, que agrega sentimientos y medidas de atención junto con las variables económicas. Dado el alto número de predictores, emplean adaptive lasso para selección y estimación, con pruebas de significancia conjunta y post-selección conservadoras.

## **Resultados principales.**

Evidencia in-sample:

- Las variables de sentimiento/atención son conjuntamente significativas (F-tests) sobre la volatilidad futura en casi todos los activos (17/18 acciones y el índice).
- La atención domina al sentimiento como forma funcional: el volumen (mensajes/búsquedas) es el predictor más relevante; el VIX aparece sistemáticamente entre las variables seleccionadas.

Desempeño out-of-sample:

- Horizonte 1 día:

## Bibliografía

- Audrino, F., Sigrist, F., & Ballinari, D. (2020). The impact of sentiment and attention measures on stock market volatility. *International Journal of Forecasting*, 36(2), 334–357.
- Christensen, K., Siggaard, M., & Veliyev, B. (2023). A machine learning approach to volatility forecasting. *Journal of Financial Econometrics*, 21(5), 1680–1727.